

KT 사례기반 AI 교육

- VOC 고객 해지 예측 모델링

1. AIDU 기본 사용법 및 데이터 분석 준비하기(완료)

2. 데이터 분석하기

3. 데이터 전처리하기

4. 머신러닝 모델 구현

5. 딥러닝 심층신경망 모델 구현

```
In [ ]: !pip install seaborn
```

```
In [ ]: # 필요 라이브러리 임포트 하기
import numpy as np
import pandas as pd

import matplotlib.pyplot as plt
import seaborn as sns
%matplotlib inline
```

```
In [ ]: # voc 데이터 읽어 들이기
df = pd.read_csv("../voc_rcp_practice.csv")
df
```

Chapter 2. 데이터 탐색하기

1. Sample 데이터 확인하기
2. 데이터 정보 확인하기
3. 통계적 특성파악하기
4. 필요한 컬럼 추출하기
5. 데이터 타입 변경하기

1. Sample 데이터 확인하기

Sample 데이터를 육안으로 확인하여 데이터의 구성과 필요 유무를 확인합니다.
head()와 tail()을 활용하여 Sample 데이터 확인이 가능합니다.

```
In [ ]: df.head()
```

```
In [ ]: df.tail()
```

```
In [ ]: df.head(20)
```

2. 데이터 정보 확인

컬럼 수, 데이터 타입 등을 확인하여 정상적 로드 확인합니다.

info()는 데이터 구성과 특성을 확인해 볼 수 있습니다.

```
In [ ]: df.info()
```

3. 통계적 특성 파악

수치 데이터에 대한 수학적 특성 확인으로 데이터 분포 확인

describe()를 통해 수학적 통계를 확인해 보는 작업을 해봅시다.

- 컬럼별 개수(count)
- 데이터의 평균값(mean)
- 표준편차(std)
- 최소값(min)
- 4분위수(25%, 50%, 75%)
- 최대값(max)

```
In [ ]: df.describe()
```

4. 필요한 컬럼만 추출하기

수집한 데이터의 컬럼이 너무 많을 경우 데이터 처리에 불필요한 시간과 자원 소모

이번 수업에서는 필요한 컬럼만 추출하여 데이터처리를 하도록 하겠습니다.

실제 분석/모델링에서는 어떤 컬럼이 중요할지 알수 없기 때문에 자원이 가능한 많은 데이터를 가지고 하셔도 좋습니다.

① 불필요한 값, 잘못된 값('-', '', '_') 확인

value_count()를 사용하여 해당 컬럼의 값 분포 확인

```
In [ ]: # 첫번째 컬럼 "voc_trt_perd_itg_cd" 데이터 확인 및 값 분포 확인
df['voc_trt_perd_itg_cd'].value_counts()
```

```
In [ ]: # 첫번째 컬럼 "voc_trt_perd_itg_cd" 값 분포 비율 확인
df['voc_trt_perd_itg_cd'].value_counts(normalize=True)
```

② 불필요한 컬럼 삭제하기

컬럼 별 '_'와 결측치 값이 50% 이상 차지하는 컬럼 삭제하고 df1 변수에 대입 drop() 함수를 사용하고, columns 파라미터를 수정

```
In [ ]: # '_' 데이터 비율이 54% 차지하는 것으로 확인됨으로 해당 컬럼은 학습 데이터로 적합하지
df = df.drop(columns=['voc_trt_perd_itg_cd'])
```

③ 날짜(Date) 관련 컬럼 확인 및 삭제

('new_date', 'opn_nfl_chg_date', 'cont_fns_pam_date')

```
In [ ]: df[['new_date', 'opn_nfl_chg_date', 'cont_fns_pam_date']].head()
```

```
In [ ]: df.drop(columns=['new_date', 'opn_nfl_chg_date', 'cont_fns_pam_date'], inplace=True)
```

5. 데이터 타입 변경하기

데이터를 불러온 후에는 반드시 데이터 타입을 확인해 주세요.

숫자형 데이터가 문자형으로 지정되어 있거나

혹은 그 반대의 경우 원하는 데이터 처리 결과가 도출되지 않을 수 있습니다.

```
In [ ]: df['age_itg_cd'].head()
```

```
In [ ]: # 숫자형 데이터가 문자형으로 저장된 경우의 사칙연산
df['age_itg_cd'][4]+df['age_itg_cd'][5]
```

```
In [ ]: # 'age_itg_cd' 항목을 Integer type으로 변경
df=df.astype({'age_itg_cd': int})

# 다른 방법
df['age_itg_cd'] = df['age_itg_cd'].astype(int)
```

```
In [ ]: # "_" 항목을 NaN 값으로 치환
df['age_itg_cd'] = df['age_itg_cd'].replace("_", np.NaN)
```

```
In [ ]: # 'age_itg_cd' 컬럼의 "_" 값이 Null 값을오 바뀐 것을 확인
df['age_itg_cd'].isnull().sum()
```

```
In [ ]: # 'age_itg_cd' 항목의 type 변경
# NaN의 경우 int type을 지원하지 않아 float type으로 변경
df=df.astype({'age_itg_cd': float})
```

```
In [ ]: df.info()
```

[실습] 데이터 탐색하기

[Q] 'df' DataFrame을 이용해서 읽어들이는 파일의 Sample 데이터를 아래의 조건들로 검색해 보세요.

- 앞 부분 3줄 데이터
- 뒤 부분 7줄 데이터
- 10번째에서 20번째까지 데이터

```
In [ ]: # 앞 부분 3줄
df.head(3)
```

```
In [ ]: # 뒤 부분 7줄
df.tail(7)
```

```
In [ ]: # 10번째에서 20번째까지 데이터
df[10:21]
```

[Q] df의 결측치('null')가 있는지 확인해 보세요.

```
In [ ]: df.info()
```

```
In [ ]: df.isnull().sum()
```

[Q] 'df'에서 컬럼 별 '_'가 50% 이상 차지하는 컬럼들을 찾으세요.

```
In [ ]: # '_' galcheochi-reul 50% isang gajin keoll-eum-eul chaeoseyo.
# [방법 1] 하나씩 확인한다.
df['voc_prod_sbt_id'].value_counts(normalize=True)
df['voc_wjt_sorc_id'].value_counts(normalize=True)
df['voc_type_itg_cd'].value_counts(normalize=True)
df['voc_sttus_itg_cd'].value_counts(normalize=True)
df['voc_trt_reslt_itg_cd'].value_counts(normalize=True)
df['cust_clas_itg_cd'].value_counts(normalize=True)
df['bprod_sbt_id'].value_counts(normalize=True)
df['age_itg_cd'].value_counts(normalize=True)
df['cont_sttus_itg_cd'].value_counts(normalize=True)
df['cust_dtl_ctg_itg_cd'].value_counts(normalize=True)
df['voc_trt_degr_div_itg_cd'].value_counts(normalize=True)
df['oos_cause_type_itg_cd'].value_counts(normalize=True)
df['voc_trt_need_time_itg_cd'].value_counts(normalize=True)
df['engt_cperd_type_itg_cd'].value_counts(normalize=True)
df['engt_tgt_div_itg_cd'].value_counts(normalize=True)
df['voc_mis_pbls_yn'].value_counts(normalize=True)
df['fcilt_oos_yn'].value_counts(normalize=True)
df['cust_snsry_base_conf_need_time'].value_counts(normalize=True)
df['trm_yn'].value_counts(normalize=True)
```

```
In [ ]: # 방법 2. for 문을 활용하여 모든 컬럼에 대한 데이터 분포 건수 확인
[ df[c].value_counts(normalize=True) for c in df ]
```

- 컬럼에서 '_' 값이 차지하는 비율

```

voc_trt_reslt_itg_cd : 0.83
oos_cause_type_itg_cd : 0.92
engt_cperd_type_itg_cd : 0.56
engt_tgt_div_itg_cd : 0.56
fclt_oos_yn : 0.92
cust_clas_itg_cd : 0.2
age_itg_cd : 0.22
cont_sttus_itg_cd : 0.11
cust_dtl_ctg_itg_cd : 0.11
voc_mis_pbls_yn : 0.008

```

```

In [ ]: #방법3. '_' 값을 null 로 변경하여 결측치 확인
df_temp = df.replace('_', np.nan)
df_temp.isnull().sum()

```

- 컬럼에서 결측치가 50%이상 차지하는 비율

```

voc_trt_reslt_itg_cd
oos_cause_type_itg_cd
engt_cperd_type_itg_cd
engt_tgt_div_itg_cd
fclt_oos_yn
cust_clas_itg_cd
age_itg_cd2
cont_sttus_itg_cd
cust_dtl_ctg_itg_cd
voc_mis_pbls_yn

```

[Q] 'df' 에서 컬럼 별 '_'가 50% 이상 차지하는 컬럼들을 삭제하세요.

```

In [ ]: df.drop(columns=['voc_trt_reslt_itg_cd',
                        'oos_cause_type_itg_cd',
                        'engt_cperd_type_itg_cd',
                        'engt_tgt_div_itg_cd',
                        'fclt_oos_yn'], inplace=True)

#df = df.drop(columns=['voc_trt_reslt_itg_cd',
#                       'oos_cause_type_itg_cd',
#                       'engt_cperd_type_itg_cd',
#                       'engt_tgt_div_itg_cd',
#                       'fclt_oos_yn']
#)

```

[Q] 'df' 에서 데이터 타입이 잘못되어 있는 컬럼이 있는 경우 변경 해주세요.

```
In [ ]: df.info()
```

```
In [ ]: df.head()
```

```
In [ ]: df = df.astype({'voc_prod_sbt_id': object,
                        'voc_wjt_sorc_id' : object,
                        'voc_type_itg_cd' : object,
                        'voc_sttus_itg_cd' : object,
                        'bprod_sbt_id' : object,
                        'voc_trt_degr_div_itg_cd': object,
                        'voc_trt_need_time_itg_cd' : object})
```

```
In [ ]: df.info()
```

※ 다음 실습을 위해 추가적으로 불필요한 컬럼 삭제와 남은 '_' 값들을 제거하겠습니다.

- 남아있는 '_'값을 Null로 변경

```
In [ ]: # cust_clas_itg_cd 컬럼에 '_' 값 있는지 확인 : 아직도 있습니다.
df[df['cust_clas_itg_cd'] == '_']
```

```
In [ ]: df.info()
```

```
In [ ]: df = df.replace('_', np.nan)
```

```
In [ ]: # 이전에 Null 없던 cust_clas_itg_cd, age_itg_cd 컬럼등에서 Null 있어 보인다.
df.info()
```

```
In [ ]: # 다음 실습을 위한 데이터 저장
df.to_csv(DATA_PATH + '/voc_rcp_practice2.csv', index=False)
```

```
In [ ]:
```